

# BLAST → DIAMOND: Konzept zur Laufzeitoptimierung

Schneller Einzelsequenz-Vergleich einer Virussequenz gegen NCBI nr

Stand: 23.09.2026 — dell-3660 (192.168.5.23)

Erzeugt von dell-3660: /home/gh/python/blast\_diamond\_pdf.py → /home/gh/diamond/tmp\_prtest/pdf/blast\_diamond.pdf

## Inhaltsverzeichnis

|    |                                              |    |
|----|----------------------------------------------|----|
| 1  | Ausgangslage                                 | 1  |
| 2  | Analyse der Ursache                          | 1  |
| 3  | Strategie: DIAMOND statt BLASTX              | 1  |
| 4  | Stand                                        | 1  |
| 5  | Append: neue Sequenzen ohne Neubau           | 2  |
| 6  | Metadaten in MariaDB (wagodb, Präfix blast_) | 4  |
| 7  | Öffentliche API                              | 6  |
| 8  | AmyloDeep auf der Tesla P4                   | 10 |
| 9  | Doppelte Datenhaltung auflösen               | 15 |
| 10 | Mögliche nächste Stufe                       | 17 |

## 1. Ausgangslage

blast2.py führt einen blastx-Lauf einer einzelnen SARS-CoV-2-Genomsequenz (~30 kb, 6 Frames) gegen die vollständige lokale NCBI-nr-Datenbank aus, eingeschränkt per **-taxids 4751** auf Fungi. Beobachtete Laufzeit: > 20 Minuten für einen einzigen Lauf.

## 2. Analyse der Ursache

| Kennzahl                 | Wert                              |
|--------------------------|-----------------------------------|
| Datenbankgröße           | 844 GB, 176 Volumes               |
| Sequenzen in nr          | 1,15 Mrd.                         |
| Residuen gesamt          | 435 Mrd.                          |
| RAM (dell-3660)          | 62 GB                             |
| genutzte Kerne im Skript | 8 von 20                          |
| GPU                      | Tesla P4, 8 GB VRAM, Pascal sm_61 |

Die Datenbank übersteigt den verfügbaren Arbeitsspeicher um mehr als das Zehnfache, der Lauf ist damit an die Platte gebunden. Der Taxid-Filter reduziert die gemeldeten Treffer, ändert aber nichts an der nötigen Wortsuche über die vollständige Datenbank. Zusätzlich wird weniger als die Hälfte der CPU-Kerne genutzt.

## 3. Strategie: DIAMOND statt BLASTX

DIAMOND (Buchfink, Xie & Huson, *Nature Methods* 2015; Weiterentwicklung Buchfink et al. 2021, „Sensitive protein alignments at tree-of-life scale“) ist ausdrücklich für den Vergleich einzelner Sequenzen gegen Datenbanken in nr-Größe

entwickelt. Der Kern ist eine Doppel-Indizierung (Query und Datenbank werden gemeinsam sortiert und geseedet, statt die Datenbank linear je Query zu durchsuchen) plus Spaced Seeds. Berichtete Beschleunigung gegenüber BLASTX: 100–20.000× bei vergleichbarer Trefferqualität; die Datenbank muss dabei nicht ins RAM passen (blockweises Streaming).

Dieselbe Grundidee (schneller Alignment-Vorfilter gegen komplette nr/nt zur Identifikation unbekannter/neuartiger Erreger) steckt hinter CZ-ID / IDseq (Kalantar et al. 2020, *GigaScience*), einer Pipeline des Chan Zuckerberg Biohub für genau diesen Anwendungsfall.

Alternative: MMseqs2 (Steinegger & Söding, *Nature Biotechnology* 2017) verfolgt denselben Vorfilter-Gedanken, ist bei höchster Empfindlichkeit etwas langsamer als DIAMOND, dafür teils treffsicherer bei entfernten Homologien. Eingesetzt wird DIAMOND: geringster Umstellungsaufwand (Drop-in für blast2.py), kein zusätzlicher Unterbau nötig.

## 4. Stand

Statt einer physischen Teil-DB (Fungi) gibt es eine vollständige `nr_full.dmnd` mit Taxonomie-Map; eingeschränkt wird bei der Suche per `--taxonlist`. Gebaut wird auf `sda5 (/mnt/archive)`.

**Ein Durchgang für .dmnd und Metadaten:** `~/python/nr_build.py` (seit 23.09.2026, ersetzt `diamond_pipeline.sh`, `filter_nonempty.py`, den Erstimport von `blast_meta2db.py` und `blast_release_finalize.sh`). Ein einziger `blastdbcmd`-Strom (je Defline OID, Accession, TaxID, Länge, Sequenz, Titel) wird verteilt: an `makedb` mit Kopfzeilen nur aus Accessions (`>acc1 >acc2 ...`, Titel nur noch in MariaDB), an MariaDB als Chunk-Dateien je 5 Mio. Sequenzen, die ein eigener Thread lädt (Warteschlange begrenzt, bremst den Strom statt die Platte zu füllen). Leersequenzen gehen nicht in die Datenbankdatei und werden in `blast_dmnd_luecke` vermerkt. Danach Verifikation beider Ziele gegen `blastdbcmd -info`, Indizes (`tmpdir` auf der NVMe), Taxonomie, `blast_release`. Erst dann nimmt die API Suchen an.

**Speicherfehler im ersten Bau (23.09.2026, 11:03):** `makedb` sammelte die Offset-Tabelle (16 Byte je Sequenz) in einem `vector (dmnd.cpp)`, der bei  $2^{30}$  Einträgen – Volume ~164 von 176 – seine Kapazität verdoppelte und kurz ~51 GB brauchte; der OOM-Killer beendete den Bau nach 3,5 h. Patch: die Einträge gehen in 1-Mio.-Blöcken in `<db>.pos_tmp` und werden am Ende in den Trailer kopiert. Geprüft an 2,5 Mio. nr-Sequenzen: Datei byteweise identisch zum unveränderten Binary, `--append` ebenfalls identisch. Gebaut wird mit `~/src/diamond/build/diamond (v2.2.8 + --append + dieser Patch)`, dem Binary, das auch die Cron-Skripte nutzen.

Eine BLAST-formatierte nr in `~/blastdb` gibt es nicht mehr. API (`acc`, Abschnitt 7.7) und AmyloDeep (`--acc/--kandidaten`, Abschnitt 8) holen Residuen über `nr_seq.py` direkt aus der `.dmnd (/home/gh/diamond/nr_full.dmnd, NVMe)`; von `makedb` zu X maskierte Bereiche kommen bei Bedarf von NCBI. Abschnitt 9 beschreibt den Stand vom 24.09.2026.

### 4.1 Durchsatz der Erstbefüllung

Gemessen am Bau vom 23.09.2026 11:34 Uhr, gelesen beim Erzeugen dieses PDFs aus `blast_import` und `nr_build.log`. Ein einziger `blastdbcmd`-Strom versorgt `makedb` (20 Threads) und den Ladethread gleichzeitig; die Werte gelten also für beide Ziele zusammen, nicht für `makedb` allein.

| Größe                                 | Wert                                                             |
|---------------------------------------|------------------------------------------------------------------|
| Laufzeit                              | 171:44 h (11,3 h gesamt)                                         |
| Sequenzen                             | 1.156.964.465 (100,3 % der nr)                                   |
| Deflines (blast_acc)                  | 1.943.564.203                                                    |
| Sequenzen/s                           | 1.871                                                            |
| Deflines/s                            | 3.143                                                            |
| Residuen/s (rechnerisch)              | 0,7 Mio., mittlere Länge 377 aa                                  |
| <code>nr_full.dmnd</code>             | 489,5 GB, 1 MB/s                                                 |
| Chunk (5 Mio. Sequenzen) nach MariaDB | 81 s (0–107 s)                                                   |
| Ladethread belegt                     | 3,4 % der Laufzeit                                               |
| CPU der Maschine (sar, 15:30:01)      | 15,0 % user, 0,0 % nice, 1,2 % system, 7,9 % iowait, 75,9 % idle |
| Last (1/5/15 min)                     | 7,48 / 8,20 / 5,79 bei 20 Threads                                |
| Leersequenzen                         | 0                                                                |

Der Ladethread ist 3,4 % der Laufzeit beschäftigt – er wartet dabei überwiegend auf MariaDB. Der Speicherbedarf von `makedb` bleibt über den ganzen Bau flach; genau das ist der Zweck des Patches aus Abschnitt 4.

**Was begrenzt, ist MariaDB – nicht DIAMOND.** Eine Messung über 5 s (`/proc/<tid>/stat` und `wchan`, 23.09.2026 16:11) fand alle Stufen außer einer im Wartezustand: `nr_build.py` 0 % in `futex_do_wait` an der vollen Warteschlange,

der Ladethread 0 % in wait\_woken am MariaDB-Socket, makedb 0 % in anon\_pipe\_read, blastdbcmd 0 % in anon\_pipe\_write. Allein mariadb lief mit 100 % an einem LOAD DATA LOCAL INFILE. Dazu passt die Warteschlange: sie ist voll, die Chunk-Dateien stehen abholbereit auf der NVMe, und der Strom wird gebremst – so, wie es gedacht ist.

Deshalb liegt die Maschine weitgehend brach und die Platten auch (NVMe 8 %, sda 11 % Auslastung, iostat, zur selben Zeit). Der nice-Anteil in der Tabelle oben ist nicht der Bau, sondern der AmyloDeep-Worker aus Abschnitt 8, der nebenher den Kontrolllauf rechnet. Eine einzige Verbindung schreibt blast\_seq und blast\_acc, beide ROW\_FORMAT=COMPRESSED: jede Seite wird beim Schreiben gepackt, und das kostet den Kern. Sekundärindizes entstehen erst nach dem Bau, sie spielen hier noch keine Rolle. Die 20 Threads von makedb bleiben in dieser Phase ohne Wirkung – sie hängen an einer Pipe, die ein einzelner Python-Prozess füllt. Schneller würde der Bau also an der Metadaten-seite, nicht an DIAMOND: mehrere Ladeverbindungen mit getrennten OID-Bereichen oder unkomprimierte Tabellen mit späterem Packen. Beides ist nicht gemessen.

## 5. Append: neue Sequenzen ohne Neubau

NCBI bietet für die BLAST-formatierte nr kein inkrementelles Update an (README blast/db: „Incremental update is not available“), und DIAMOND kann an eine bestehende .dmnd nichts anhängen. Beides wurde ergänzt.

### 5.1 Patch diamond makedb --append

Branch makedb-append in ~/src/diamond, Diff in ~/src/diamond-makedb-append.patch (3 Dateien, ~140 Zeilen), Binary ~/src/diamond/build/diamond (v2.2.8 + Patch). Aufbau einer .dmnd: Header, Sequenzen, danach der Trailer aus Offset-Tabelle, Taxon-Listen (varint-kodiert je OID, ohne eigenen Index), Taxonomie-Knoten und Namen; der Header wird zuletzt per seek(0) geschrieben. Ablauf von --append:

1. Header lesen und prüfen (Magic, Version 3, gleiche –taxonmap/–taxonnodes/–taxonnames-Nutzung wie beim Erstbau).
2. Header und kompletten Trailer in <db>.append\_backup sichern (bei nr ca. 20–25 GB).
3. Datei am Ende der Sequenzen abschneiden (pos\_array\_offset), neue Sequenzen dahinter schreiben. Der fortlaufende MurmurHash3 läuft vom gespeicherten Wert weiter.
4. Trailer neu schreiben: alte Offset-Einträge + neue, alte Taxon-Listen byteweise + neue (TaxonList::build nur für die neuen OIDs), Taxonomie aus dem aktuellen taxdump.
5. Header schreiben, Backup löschen. Bei jedem Fehler stellt der Patch Header und Trailer aus dem Backup wieder her.

**Tests (23.09.2026):** (1) DB aus A (12.000 Sequenzen) plus --append von B (8.000) ist **byteweise identisch** mit der in einem Durchgang gebauten DB aus A+B (cmp), inkl. Hash, Taxon-Listen und Header. (2) Append mit einer Sequenz der Länge 0 bricht ab, die DB ist danach byteweise identisch zum Stand vorher, kein Backup-Rest. (3) diamond blastp mit Ausgabe staxids auf der erweiterten DB liefert korrekte Treffer.

### 5.2 Update-Skript diamond\_append.py

Erkennung eines neuen Releases: nr-prot-metadata.json von NCBI (last-updated, number-of-sequences) gegen den neuesten Eintrag in blast\_release; gleich = sofort Ende. Bei neuem Release: Volume für Volume laden (md5 geprüft), entpacken, Accessions gegen ein sortiertes 64-bit-Hash-Array aller bekannten Accessions (~15 GB, per Memory-Map) prüfen, Volume löschen. Spitzenbedarf ein Volume statt 855 GB. Neu ist eine Sequenz, wenn keine ihrer Accessions bekannt ist. Danach genau ein --append (Zustandsdatei verhindert doppeltes Anhängen), Metadaten in blast\_seq/blast\_acc mit neuen OIDs ab dem bisherigen Maximum, neue Zeile in blast\_release, Mail an gh@heissa.de. Fortsetzbar je Volume. Wann eine Sequenz hinzukam, liefern die Views blast\_seq\_herkunft/blast\_acc\_herkunft (OID-Bereich in blast\_import → Release).

**Ende-zu-Ende-Test** mit Testtabellen blasttest\_\*: Bestand A, „neues Release“ = Volume nr.000 bis zur 20.000. Sequenz. Ergebnis: genau 8.000 neue Sequenzen erkannt, .dmnd danach byteweise identisch zur Voll-DB, Metadaten per Prüfsumme identisch zur Produktion, zweiter Lauf erkennt „kein neues Release“.

**Grenzen:** neue Accessions an bereits vorhandenen Sequenzen (neuer Organismus für dieselbe Sequenz) und von NCBI zurückgezogene Sequenzen werden nur gezählt und erst bei einem Vollneubau berücksichtigt. 64-bit-Hash: rechnerisch ~0,2 fälschlich als bekannt eingestufte Accessions je Release-Abgleich.

Sequenzen, die bereits per Tagesdelta (5.3) angehängt wurden, erkennt das Skript am Sequenz-Hash und hängt sie nicht ein zweites Mal an (Zähler „schon per Tagesdelta“). Der MariaDB-Teil läuft in einer Transaktion (6.4). Test mit Testtabellen: 3.000 Sequenzen, davon 1.000 schon in nr (Accession) und 10 schon per Tagesdelta (Sequenz) → genau 1.990 angehängt, alte Release-Zeilen unverändert.

### 5.3 Tagesdelta nr\_daily\_delta.py

Die BLAST-nr wird von NCBI nur als Ganzes neu erzeugt (letzter Stand 16.09.2026, blast/db/FASTA/nr.gz seit 06.02.2024 eingefroren). Zwischen zwei Releases kommen neue Proteine aus den Tagesdateien: genbank/daily-nc/ncMMDD.gnp.gz (GenPept, ~180 Tage vorgehalten) und refseq/daily/rsnc.MMDD.YYYY.gpff.gz (~21 Tage). Das GenPept-Format enthält Accession, Titel, TaxID (/db\_xref="taxon:"), Sequenz und in der LOCUS-Zeile das NCBI-Datum.

**Duplikate nach Sequenz, nicht nach Accession:** nr fasst identische Proteine zu einem Eintrag zusammen, führt dabei aber nicht jede Accession auf (Beispiel: YGQ27362.1 ist sequenzgleich zu YP\_009724396.1, dessen nr-Eintrag nur 7 Deflines hat). Ein Abgleich nach Accession würde also massenhaft Duplikate anhängen. Deshalb: blake2b-64-Hash jeder Sequenz (Großbuchstaben) gegen das sortierte Hash-Array aller nr-Sequenzen (/mnt/archive/nr\_seq\_hashes.npy, 9,2 GB, per Memory-Map) plus die im selben Lauf schon gesehenen. Alle offenen Tagesdateien werden in **einem** --append verarbeitet, die TaxID-Zuordnung kommt als kleine Mapping-Datei aus dem GenPept selbst.

**Test (23.09.2026, Testtabellen, Test-dmnd):** nc0919 (19.09.): 5.189 Proteine, 100 schon in der Test-„nr“, 3.195 innerhalb der Datei doppelt, 1.894 neu; nc0920: 7.104 Proteine, 6.491 neu. dmnd danach 100 + 8.385 Sequenzen, OIDs in MariaDB lückenlos, jede neue Sequenz mit NCBI-Datum; zweiter Lauf: „Keine offenen Tagesdateien“. Beispiel einer neuen humanen Sequenz: BIN93201.1 *spexin precursor, partial [Homo sapiens]*, NCBI-Datum 19.09.2026.

**Cron:** 03:30 diamond\_append.py (neues nr-Release), 04:30 nr\_daily\_delta.py (Tagesdateien). Beide nehmen dieselbe Sperre /home/gh/.nr\_dmnd.lock und warten, bis der Erstaufbau (dmnd\_hash und meta\_importiert in blast\_release) abgeschlossen ist. Nach einem neuen nr-Release beginnt das Tagesdelta ab dessen Datum; die zwischenzeitlich per Delta angehängten Sequenzen überspringt der Release-Abgleich per Sequenz-Hash.

**Robustheit (seit 30.09.2026):** (1) Läuft um 04:30 noch diamond\_append.py (ein neues nr-Release braucht Stunden), wartet das Delta bis zu 12 h auf die Sperre (LOCK\_WAIT\_H), statt den Tag auszulassen. (2) Die Hash-Caches werden blockweise fortgeschrieben (merge\_in\_datei: alte Datei per Memory-Map, neue per open\_memmap, Blöcke zu 2<sup>26</sup> Einträgen) statt mit np.union1d im RAM – das brauchte für nr\_acc\_hashes.npy (15,5 GB) rund 47 GB und endete am 30.09. im OOM-Kill; jetzt ~0,8 GB anonymer Speicher. (3) Findet ein Lauf ein altes ~/nr\_daily/state.json, dessen Tagesdateien alle schon in blast\_release stehen, war der Metadaten-Commit durch und der Lauf starb erst danach: er trägt die Sequenz- und Accession-Hashes aus den liegengebliebenen .fa/.acc.tsv nach (mehrfach harmlos) und leert das Verzeichnis – auch wenn keine neuen Tagesdateien offen sind. Fehlen dagegen Metadaten, bricht er weiter mit Fehler ab (dmnd und MariaDB könnten auseinanderlaufen).


## 6. Metadaten in MariaDB (wagodb, Präfix blast\_)

Die .dmnd-Datei kennt nur Sequenzen, Accessions als Namen und TaxIDs – kein Datum, keinen NCBI-Stand, keine Herkunft. Auch die BLAST-nr enthält kein Einreichungsdatum. Fragen wie „welcher nr-Stand ist geladen“, „seit wann ist diese Sequenz in der DB“ oder „wann kam die letzte humane Sequenz hinzu“ lassen sich deshalb nur über die Metadaten in MariaDB beantworten. Sie sind zugleich die Grundlage der API (Treffer aus DIAMOND per Accession mit Titel, Organismus und Taxonomie anreichern). Jedes Skript, das die .dmnd verändert, pflegt im selben Lauf auch diese Tabellen.

### 6.1 Tabellen

| Tabelle        | Zeilen (nr 09/2026) | Inhalt                                                                                          |
|----------------|---------------------|-------------------------------------------------------------------------------------------------|
| blast_seq      | 1,15 Mrd.           | je Sequenz: oid (PK), Länge, Zahl der Accessions, Titel der ersten Defline                      |
| blast_acc      | ~1,94 Mrd.          | je Defline: oid, pos, acc, taxid; Index auf acc und taxid                                       |
| blast_taxon    | ~2,7 Mio.           | NCBI-Taxonomie: taxid, parent, rank, wissenschaftlicher Name                                    |
| blast_release  | 1 + 1 je Tagesdatei | Stand: quelle (nr / genbank-daily / refseq-daily), datei, nr_datum, Sequenzen, dmnd_hash, aktiv |
| blast_import   | 231 + 1 je Delta    | OID-Bereich first_oid..last_oid → release_id, Zeitpunkt geladen                                 |
| blast_seq_ncbi | nur Delta-Sequenzen | oid → NCBI-Datum aus der GenPept-LOCUS-Zeile                                                    |

blast\_seq und blast\_acc sind InnoDB ROW\_FORMAT=COMPRESSED. Beim Import-Zwischenstand (140 Mio. Sequenzen) belegen beide je 6,3 GB; hochgerechnet auf die ganze nr je ~52 GB, dazu die beiden Indizes auf blast\_acc. Alles liegt auf der System-NVMe (/var/lib/mariadb).



ER-Diagramm der nr-Metadaten, erzeugt aus dem Live-Schema (information\_schema). Durchgezogen: deklarierte Fremdschlüssel, gestrichelt: logische Verknüpfungen; Krähenfuß = viele. PK/UK/IX/FK wie in der Datenbank; Indizes auf blast\_acc erscheinen, sobald nr\_build.py sie gebaut hat.

## 6.2 Herkunft und Datum je Sequenz

Jede Sequenz gehört über ihren OID-Bereich in blast\_import zu genau einer Zeile in blast\_release. Die Views blast\_seq\_herkunft und blast\_acc\_herkunft lösen das auf: quelle, datei, nr\_stand, ncbi\_datum, hinzugefügt (Zeitpunkt des Imports). Grenze: alle Sequenzen des Erstimports tragen nur den nr-Stand 16.09.2026, denn die BLAST-nr liefert kein Einreichungsdatum. Ein echtes Tagesdatum haben erst die Sequenzen aus dem Tagesdelta (ncbi\_datum aus der LOCUS-Zeile).

**OID-Nummern:** die OIDs in MariaDB sind die BLAST-OIDs, fortgezählt für angehängte Sequenzen. Sie stimmen nicht mit der Satznummer in der .dmnd überein (leere Sequenzen beim Bau verworfen). Verknüpft wird deshalb über die Accession (DIAMOND-Ausgabe sseqid → blast\_acc.acc).

## 6.3 Beispielabfragen

```
-- welcher Stand ist geladen?
SELECT quelle, datei, nr_datum, nr_sequenzen, dmnd_hash
FROM blast_release ORDER BY nr_datum DESC LIMIT 5;

-- wann kam die letzte humane Sequenz hinzu?
SELECT acc, quelle, datei, ncbi_datum, hinzugefuegt
FROM blast_acc_herkunft WHERE taxid = 9606
ORDER BY hinzugefuegt DESC, ncbi_datum DESC LIMIT 1;

-- neue Sequenzen je Tag
SELECT n.ncbi_datum, COUNT(*) FROM blast_seq_ncbi n GROUP BY 1 ORDER BY 1 DESC;

-- DIAMOND-Treffer anreichern
SELECT a.acc, s.title, t.name FROM blast_acc a
JOIN blast_seq s USING (oid) JOIN blast_taxon t ON t.taxid = a.taxid
WHERE a.acc = 'YP_009724390.1';
```

## 6.4 Wer schreibt was

| Skript                                         | Wann                                                   | Schreibt                                                                                                                                                      |
|------------------------------------------------|--------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| blast_meta2db.py                               | einmalig (Erstaufbau)                                  | blast_seq, blast_acc in 231 Stücken zu je 5 Mio. Sequenzen (LOAD DATA LOCAL, ~95 s je Stück, fortsetzbar über blast_import), danach Indizes und blast_taxon   |
| blast_release_finalize.sh<br>diamond_append.py | nach Build + Import<br>Cron 03:30, neues<br>nr-Release | dmnd_hash, dmnd_sequenzen, meta_importiert für den Erststand<br>neue blast_release-Zeile (quelle nr), OID-Bereich, blast_seq/blast_acc<br>der neuen Sequenzen |
| nr_daily_delta.py                              | Cron 04:30,<br>Tagesdateien                            | je Tagesdatei eine blast_release-Zeile, OID-Bereich,<br>blast_seq/blast_acc/blast_seq_ncbi                                                                    |

**Konsistenz .dmnd ↔ MariaDB:** die Append-Skripte hängen erst an die .dmnd an und merken sich das in einer Zustandsdatei (dmnd\_done, Hash, Sequenzzahl). Danach schreiben sie alle Metadaten in **einer** Transaktion. Bricht dieser Teil ab, rollt MariaDB vollständig zurück; der nächste Lauf hängt nicht erneut an, er trägt nur die Metadaten nach. Getestet: bei absichtlich fehlender Tabelle blieb MariaDB auf dem alten Stand, die .dmnd wurde nicht doppelt erweitert (Hash unverändert), der Nachlauf ergänzte genau die fehlenden 8.385 Sequenzen. Die Hash-Arrays (Accessions, Sequenzen) werden erst nach dem Commit fortgeschrieben.

**Zugangsdaten:** alle BLAST-Skripte holen sie über ~/python/blast\_db.py (liest DB\_CFG aus ~/mqtt-listener.py, Datenbank wagodb).

## 6.5 Zeichensatz-Falle bei Joins auf blast\_acc.acc

blast\_acc.acc ist ascii, Tabellen wie aml\_sequenz.acc sind utf8mb4. MariaDB wandelt dann die blast\_acc-Spalte um und kann idx\_acc nicht benutzen: Vollscan über 1,9 Mrd. Zeilen, die View aml\_v\_ergebnis hängt. Mit a.acc = CONVERT(s.acc USING ascii) nutzt der Join den Index (344 Treffer in 0,003 s). Dauerhaft ergänzt eine virtuelle Spalte acc\_u VARCHAR(32) CHARACTER SET utf8mb4 COLLATE utf8mb4\_general\_ci AS (acc) VIRTUAL mit Index idx\_acc\_u die Tabelle (Skript blast\_acc\_utf8mb4\_index.sh, zwei ALTER TABLE, online; Bau gestartet am 24.09.2026 08:49, dauert Stunden). Danach joinen utf8mb4-Tabellen mit a.acc\_u = s.acc ohne CONVERT.

## 7. Öffentliche API

Damit auch andere die DIAMOND-Suche und die Metadaten nutzen können, gibt es eine minimale JSON-API: <https://yt.heissa.de/blast/api.php>. yt.heissa.de hat nur einen AAAA-Eintrag, die API ist von außen also **nur über IPv6** erreichbar (von heissa.de aus getestet). Ohne Parameter liefert sie ihre eigene Beschreibung.

### 7.1 Endpunkte

| Aufruf                                          | Zugang           | Liefert                                                                                                                        |
|-------------------------------------------------|------------------|--------------------------------------------------------------------------------------------------------------------------------|
| GET ?r=release                                  | frei             | geladener nr-Stand, Tagesdeltas seitdem, Bereitschaft von Suche und Metadaten, Warteschlange                                   |
| GET ?r=release → ram                            | frei             | freier Speicher (MemAvailable), Grenze einer Suche, Messwerte k je Modus/Sensitivität (Abschnitt RAM-Planung)                  |
| GET ?r=acc&acc=YP_009724390.1                   | frei             | Titel, Länge, Herkunft/Datum der Sequenz, TaxID mit Namen, alle identischen Einträge (bis 200). Ohne .Version: neueste Version |
| GET ?r=taxon&taxid=9606 bzw. &name=Homo sapiens | frei             | Taxon mit vollständiger Abstammungslinie                                                                                       |
| POST ?r=search                                  | X-API-Key        | legt einen Suchauftrag an (Query per seq oder acc); Antwort 202 mit job_id, Position und Ergebnis-URL                          |
| GET ?r=job&id=...                               | wer die id kennt | Status, Parameter, Laufzeit, nr-Stand/dmnd_hash der Suche; wenn fertig die Treffer mit Titel und Taxon-Namen aus MariaDB       |

**Suchparameter** (Formular oder JSON): seq (FASTA oder rohe Sequenz, bis 50 Sequenzen / 100.000 Buchstaben) oder acc (Accession aus nr, optional mit range von-bis, nur blastp; siehe 7.7), mode blastp oder blastx, taxonlist (bis 20 TaxIDs samt Untertaxa, z.B. 4751 = Fungi, 9606 = Mensch), len\_min/len\_max (Länge der Treffersequenz), neu\_tage (bei NCBI angelegt in den letzten N Tagen), evalve (Standard 0,001), max\_target\_seqs (1–500, Standard 25), sensitivity fast bis ultra-sensitive (Standard sensitive). Das Ergebnis enthält zusätzlich vorauswahl, block\_size, ram\_schaetz\_gb, ram\_gb (gemessen) und ram\_frei\_gb.

```
curl -X POST -H 'X-API-Key: ...' -H 'Content-Type: application/json' \
-d '{"seq": ">q1\nMKT...", "mode": "blastp", "taxonlist": "9606"}' \
'https://yt.heissa.de/blast/api.php?r=search'


curl 'https://yt.heissa.de/blast/api.php?r=job&id=18a8ceae9fcc7d63063e5ffc'
```

## 7.2 Aufbau

**api.php** (/var/www/blast, mod\_php, Alias im vHost yt.heissa.de vor dem Invidious-Proxy) beantwortet Metadaten-Anfragen direkt und legt Suchen nur als Zeile in blast\_job an. Bei acc holt sie die Query-Sequenz vorher per nr\_seq.py ACC [--range von-bis] aus der .dmnd (Direktzugriff über die Offset-Tabelle, ~0,1 s; Abschnitt 9). Eine DIAMOND-Suche gegen die volle nr belegt alle 20 Kerne für Minuten und darf deshalb nie im Webserver-Prozess laufen.

**blast\_api\_worker.py** (systemd blast-api-worker, Benutzer gh) holt die Aufträge nacheinander, ruft DIAMOND auf (Zeitlimit 1 h), schreibt die Treffer in blast\_job\_hit und vermerkt nr-Stand und dmnd\_hash. Während der Suche hält er eine geteilte Sperre auf /home/gh/.nr\_dmnd.lock; die Append-Skripte brauchen die exklusive Sperre und verändern die .dmnd daher nie unter einer laufenden Suche. Nach einem Absturz setzt er hängende Aufträge wieder auf queued. Solange dmnd\_hash im aktiven Release fehlt (Erstaufbau), nimmt die API keine Suchen an (503).

| Tabelle          | Inhalt                                                                                                                                     |
|------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| blast_api_key    | Schlüssel nur als sha256, Name, E-Mail, Tageskontingent, aktiv                                                                             |
| blast_job        | Auftrag: Parameter, Query, Status, Zeiten, Laufzeit, release_id, dmnd_hash, Trefferzahl, Fehler                                            |
| blast_job_hit    | Treffer im DIAMOND-Format 6 (qseqid ... bitscore, staxids)                                                                                 |
| blast_api_hits   | Zähler je IP bzw. IPv6-/64 und Minute (Ratenbegrenzung), vom Worker aufgeräumt                                                             |
| blast_ram_mess   | Spitzen-RSS jeder Suche (Modus, Sensitivität, Anfrage- und DB-Reste, block_size, Schätzung, freier Speicher) – Grundlage der RAM-Schätzung |
| blast_ram_status | eine Zeile: MemAvailable, MemTotal, SwapFree; vom Worker alle 30 s geschrieben                                                             |



ER-Diagramm der API (grau: Tabellen aus Abschnitt 6, nur verknüpfte Spalten), erzeugt aus dem Live-Schema (information\_schema). Durchgezogen: deklarierte Fremdschlüssel, gestrichelt: logische Verknüpfungen; Krähenfuß = viele. PK/UK/IX/FK wie in der Datenbank.

### 7.3 Vorauswahl über MariaDB (dmnd\_vorauswahl.py)

Die .dmnd hat außer der Offset-Tabelle (16 Byte je Sequenz, pos\_array\_offset) keinen Index; einen Seed-Index (diamond makeidx, .seed\_idx) erlaubt DIAMOND nur bis 100 Mio. Reste (MAX\_LETTERS in data/index.cpp), die nr hat 436 Mrd. Jede Suche baut die Seeds daher neu und liest die ganze Datei – auch mit --taxonlist. Schneller wird sie nur, wenn weniger Sequenzen durchsucht werden: Sind taxonlist, len\_min/len\_max oder neu\_tage gesetzt, bestimmt MariaDB die OIDs (Taxon samt Untertaxa per rekursiver CTE über blast\_taxon.parent und blast\_acc.idx\_taxid; Länge über blast\_seq; Anlagedatum über blast\_seq\_ncbi.createdate), dmnd\_getseq.Dmnd holt die Sätze über die Offset-Tabelle, und diamond makedb baut daraus eine Teil.dmnd in ~/diamond/vorauswahl (Cache 2 Tage, Schlüssel = Kriterien + dmnd\_hash). Gesucht wird mit --dbsize = Reste der vollen nr, damit die E-Werte mit einer Vollsuche vergleichbar bleiben; die Taxa der Treffer trägt der Worker aus blast\_acc nach. Über 50 Mio. Sequenzen (VORAUSWAHL\_MAX\_SEQ) lohnt die Teil.dmnd nicht mehr: dann Vollsuche mit --taxonlist und Nachfilter auf Länge/Datum.

| Vorauswahl       | Sequenzen     | Aufbau | Suche TTR 20–70               |
|------------------|---------------|--------|-------------------------------|
| keine (volle nr) | 1.156.964.465 | –      | 895 s (fast, -b 2)            |
| neu_tage=90      | 2.543.725     | 31 s   | 1,8 s fast / 12,9 s sensitive |
| neu_tage=4       | 71.699        | 1,0 s  | –                             |

**Grenze des Datumsfilters:** createdate gibt es nur für die per Tagesdelta angehängten Sequenzen (ab 16.09.2026) – für die 1,15 Mrd. Sequenzen des nr-Stands nicht, und die BLAST-Datenbank selbst trägt kein Datum je Sequenz. Nachfüllen für den nr-Stand: blast\_ncbi\_nachfuellen.py liest die GenBank-Tagesdateien ab 02.07.2026 (3,25 Mio. OIDs des nr-Stands), danach holt blast\_createdate\_fill.py --von-vorn das Anlagedatum per esummary.

RefSeq-Tagesdateien reichen nur ~4 Wochen zurück.

## 7.4 RAM-Planung jeder Suche

DIAMOND lädt die Datenbank in Blöcken von `--block-size` Mrd. Resten; je Shape (Anzahl je nach Sensitivität) entsteht eine Seed-Tabelle mit ~18 Byte je Seed. Bei kleinen Anfragen filtert DIAMOND die Seeds des Blocks gegen die Seeds der Anfrage (`query_seeds_hashed`), der Bedarf hängt daher stark von der Anfragegröße ab. Die `.dmnd` liefert nur die Reste-Zahl (Kopf, letters); der Rest wird gemessen. Der Worker rechnet vor jeder Suche:

1. Grenze =  $\min(48 \text{ GB}, \text{MemAvailable} - 4 \text{ GB Reserve})$ , direkt vor dem Start aus `/proc/meminfo`.
2. Bedarf =  $0,5 \text{ GB} + k \cdot \min(\text{Reste der DB}, b)$  (in Mrd. Resten).  $k$  (GB je Mrd. Reste) = größter Messwert in `blast_ram_mess` bei gleichem Modus und gleicher Sensitivität mit Anfrage im Bereich  $q/4 \dots 4q$ , sonst aus größeren Anfragen, sonst Startwert; plus 20 % Sicherheit.
3.  $b$  = größte Stufe aus  $2 / 1 / 0,5 / 0,25 / 0,1$ , deren Bedarf unter die Grenze passt (weniger Blöcke = schneller). Passt keine, wartet der Worker bis 30 min auf freien Speicher, dann Fehler.
4. DIAMOND läuft unter `/usr/bin/time -f %M`; das Spitzen-RSS geht mit Schätzung und freiem Speicher in `blast_ram_mess` und in den Auftrag (`ram_gb`). Jede Suche macht die nächste Schätzung genauer.

Startwerte  $k$ : fast 1,5, sensitive 3, mid-sensitive 3, more-sensitive 5, very-sensitive 8, ultra-sensitive 12;  $\times 2$  bei Anfragen über 5.000 Reste und bei `blastx`. fast und sensitive stammen aus Messungen (Block-Test 24.09., Teil-.dmnd 30.09.), die übrigen sind vorsichtige Annahmen, bis Messungen vorliegen. Apache sieht `/proc/meminfo` nicht (systemd `ProcSubset=pid`), daher schreibt der Worker den Speicherstand für `?r=release` alle 30 s nach `blast_ram_status`. Seit 30.09.2026 hat der dell zusätzlich 32 GB Swap auf der NVMe (`/swapfile`, `vm.swappiness=10`) als Puffer gegen OOM-Kills.

**Test (30.09.2026, extern über heissa.de):** SARS-CoV-2-Spike YP\_009724390.1 als S1 (Rest 14–685) und S2 (686–1273), 1.260 aa, ultra-sensitive, `neu_tage=100`. Vorauswahl 2.544.520 Sequenzen / 1,08 Mrd. Reste in 37,3 s (OIDs 5,5 s, Sätze 27,5 s, `makedb` 4,3 s), Suche 46 s, Auftrag gesamt 113,8 s. RAM: frei 52,3 GB, Schätzung 16,1 GB (Startwert), gemessen 1,88 GB bei `--block-size 2 - k = 1,27` GB je Mrd. Reste steht seitdem als Messwert in `blast_ram_mess`. Ohne Trefferobergrenze (direkt auf dem dell, 57,6 s): S1 506 Treffer ( $265 \geq 90\%$  Identität), S2 510 Treffer ( $382 \geq 90\%$ ).

## 7.5 Schutz

Eigener MariaDB-Benutzer `blast_api`: nur SELECT auf die Metadaten-Tabellen und Views, INSERT nur auf `blast_job`, INSERT/UPDATE nur auf `blast_api_hits`, SELECT auf `blast_ram_mess/blast_ram_status`; Zugangsdaten in `/etc/blast_api.ini` (root:www-data, 640). Alle Abfragen mit Prepared Statements, Eingaben per Muster geprüft; `nr_seq.py` wird ohne Shell mit geprüfter Accession/Range aufgerufen. 60 Anfragen je Minute und Client. Suchen nur mit Schlüssel, höchstens 3 offene Aufträge je Schlüssel, Tageskontingent je Schlüssel (Standard 20). Die `job_id` ist 96 bit Zufall und zugleich die Berechtigung zum Lesen des Ergebnisses. Accession-Abfragen antworten mit 503, bis der Index `idx_acc` existiert – ohne ihn wäre jede Abfrage ein Scan über 1,9 Mrd. Zeilen.

**Schlüssel verwalten** (auf dem dell): `python3 ~/python/blast_api_key.py add NAME [EMAIL] [JOBS_PRO_TAG]` gibt den Schlüssel einmalig aus; `list` zeigt alle mit Zahl der Aufträge; `off KEY_ID` sperrt einen.

## 7.6 Test (23.09.2026)

Von außen (heissa.de, IPv6): Beschreibung, release, Fehlerfälle (kein/falscher Schlüssel, ungültige Sequenz, ungültige id, Index fehlt) liefern die erwarteten Codes. Suchweg Ende zu Ende gegen eine Test-dmnd (Tagesdatei nc0920, 6.491 Sequenzen): `blastp` der humanen Sequenz BIN93201.1 mit `taxonlist=9606` → 1 Treffer, 100 % Identität, E-Wert  $3e-72$ , 0,5 s. Titel und Taxon-Namen erscheinen, sobald der Metadatenimport Index und Taxonomie geladen hat. Testdaten danach entfernt. Der `acc`-Weg ist noch nicht Ende zu Ende gelaufen: solange `diamond makedb` läuft, antwortet die Suche mit 503.

## 7.7 Beispiel: SARS-CoV-2-Spike-RBD gegen humane Proteine

Frage: hat die Rezeptorbindedomäne (RBD) des Spike-Proteins Ähnlichkeit mit menschlichen Proteinen? Übergeben wird nur die **Query**, also die Sequenz, zu der Treffer gesucht werden. Die Vergleichsseite ist immer die komplette `nr(nr_full)`.

dmnd); taxonlist=9606 beschränkt die Treffer auf *Homo sapiens*, mode=blastp vergleicht Protein gegen Protein.

**Variante A – Query per Accession.** Die Spike-Sequenz liegt selbst in nr (YP\_009724390.1, 1.273 aa). Die RBD sind die Reste 319–541 (223 aa); die API schneidet sie per range heraus, die Query heißt dann YP\_009724390.1\_319–541:

```
curl -X POST -H 'X-API-Key: YOUR_API_KEY' -H 'Content-Type: application/json' \
-d '{"acc": "YP_009724390.1", "range": "319-541", "mode": "blastp",
    "taxonlist": "9606", "max_target_seqs": 25}' \
'https://yt.heissa.de/blast/api.php?r=search'
```

**Variante B – Query als Sequenz**, z.B. für eine eigene oder noch nicht in nr enthaltene Variante. Dieselbe RBD als FASTA; Zeilenumbrüche in der Sequenz sind erlaubt:

```
cat > rbd.fa <<'EOF'
>SARS-CoV-2_Spike_RBD
RVQPTEIVRFPNITNLCPFGEVFNATRFASVYAWNKRKISNCVADYSVLYNSASFSTFK
CYGVSPTKLNDLCFTNVYADSFVIRGDEVQRQIAPGQTGKIADYNYKL PDDFTGCVIAWNS
NNLDSKVGNNYLYRLFRKSNLKPFFERDISTEIQAGSTPCNGVEGFNCYFPLQSYGFQ
PTNGVGYPYRVVLSFELLHAPATVCGPKKSTNLVKNKCVNF
EOF
curl -X POST -H 'X-API-Key: YOUR_API_KEY' \
--data-urlencode seq@rbd.fa -d mode=blastp -d taxonlist=9606 -d max_target_seqs=25 \
'https://yt.heissa.de/blast/api.php?r=search'
```

Als JSON geht es ebenso, dann steht die Sequenz in einer Zeile im Feld seq (FASTA-Kopf mit \n davor). seq und acc zusammen werden abgelehnt (400); eine Accession, die nicht in der BLAST-nr vom 16.09.2026 steht, ergibt 404 – dann Variante B nehmen.

**Antwort und Ergebnis:** der POST liefert sofort 202 mit job\_id, Position in der Warteschlange und Ergebnis-URL; diese abfragen, bis status = done ist:

```
{ "job_id": "...", "status": "queued", "position": 1,
  "url": "https://yt.heissa.de/blast/api.php?r=job&id=..." }

curl 'https://yt.heissa.de/blast/api.php?r=job&id=...'
```

Jeder Treffer enthält die DIAMOND-Spalten (sseqid, pident, length, qstart–qend, sstart–send, evalue, bitscore) plus Titel und Taxon-Namen aus MariaDB. Aussagekräftig sind vor allem E-Wert und Identität über die ausgerichtete Länge; kurze Treffer mit E-Wert nahe 0,001 sind meist Zufall.

## 8. AmyloDeep auf der Tesla P4

Zweite Anwendung auf denselben Sequenzen: Vorhersage der Amyloid-Neigung mit Protein-Sprachmodellen. AmyloDeep 0.3.1 (Davtyan, Khachatryan & Petrosyan, bioRxiv 2025, doi 10.1101/2025.09.16.676495; PyPI amylodeep, Gewichte AlisaDavtyan/amylodeep-models auf Hugging Face) ist ein Ensemble aus fünf Modellen: ESM-2 150M (feinjustiert), UniRep mit Klassifikationskopf, ESM-2 650M (Mean-Embedding) mit Kopf sowie SVM und XGBoost auf denselben 650M-Embeddings. Die Einzelwahrscheinlichkeiten werden kalibriert (Platt bzw. isotonisch) und gemittelt. Bewertet wird ein Rollfenster (Standard 10 Reste, Schritt 1); jedes Fenster wird auf 128 Token aufgefüllt.

### 8.1 Passt es in die P4?

| Modell                               | Gewichte FP32           | auf der P4                      |
|--------------------------------------|-------------------------|---------------------------------|
| ESM-2 150M (feinjustiert)            | ~0.6 GB                 | ja                              |
| ESM-2 650M (esm2_t33_650M_UR50D)     | ~2.6 GB                 | ja                              |
| zusammen, dazu llama-server (0,8 GB) | ~4,1 GB von 7,5 GB      | ja, FP32, kein FP16 nötig       |
| zum Vergleich: ESM-2 3B              | ~11,4 GB (FP16 ~5,7 GB) | nein bzw. nur ohne llama-server |

UniRep läuft über JAX auf der CPU, SVM und XGBoost ebenfalls; die Torch-Modelle liegen auf der GPU.

### 8.2 Umgebung: Env iver mit CUDA 11.8

Das micromamba-Env iver (~/.iver\_sim/mamba/envs/iver) war auf CUDA 11.8 gepinnt, enthielt aber nur einen **CPU-Build** von PyTorch 2.5.1. Ersetzt durch den conda-forge-Build pytorch 2.5.1 cuda118; dessen Architekturliste

enthält `sm_61` nativ, ein eigener Compile war nicht nötig. Dazu kamen `cudnn`, `magma` und `nccl`; `libprotobuf` 5.28.3 → 5.28.2.

Der nächste Install hätte PyTorch sofort wieder auf 2.10 CPU und `numpy` auf 2.x gezogen. Deshalb stehen in `conda-meta/pinned` jetzt zusätzlich `pytorch 2.5.1 cuda118*`, `libtorch 2.5.1 cuda118*` und `numpy 1.26.*` (Sicherheit `pinned.bak-20260923`). Installiert: `transformers 5.16.1`, `huggingface_hub 1.32`, `jax/jaxlib 0.5.2` (CPU), `xgboost 3.4.2` (CPU), `equinox`, `optax`, `optuna`; `amylodeep 0.3.1` und `jax-unirep 3.0.0` per `pip` mit `--no-deps`. `openmm.testInstallation` danach unverändert fehlerfrei (CUDA und OpenCL).

**Ausführbarer Stack:** Kernel 7.0 mit `glibc 2.43` lädt keine Bibliotheken mehr, die einen ausführbaren Stack anfordern (`cannot enable executable stack`). Betroffen war nur `jaxlib/xla_extension.so`: im Programmkopf `PT_GNU_STACK` das X-Bit gelöscht (RWE → RW), Original unter `~/iver_sim/xla_extension.so.orig`. Nach einem `jaxlib`-Update ist das zu wiederholen.

### 8.3 `amylo_gpu.py`

`~/iver_sim/ol_amyloid/amylo_gpu.py` erbt von `EnsembleRollingWindowPredictor`, ohne das Paket zu verändern. Das Paket selbst rechnet nur auf der CPU und führt ESM-2 650M für dieselben Fenster dreimal aus (NN-Kopf, SVM, XGBoost). Der Wrapper legt die Torch-Modelle auf CUDA, rechnet in Stapeln zu 64 und die 650M-Embeddings je Fenstermenge nur einmal. Eingabe: Sequenz, FASTA, `--acc` oder `--kandidaten` (TSV Accession, Kürzel); Sequenzen über `nr_seq.py` aus der `.dmnd`, X-Maskierung per NCBI ausgeglichen (siehe Abschnitt 9).


**Prüfung gegen das Original** (`--vergleich`), A $\beta$ 42 (42 aa, 33 Fenster): größte Abweichung je Fenster 7e-7, GPU 4,4 s gegen 43,4 s CPU. Die stärksten Fenster liegen auf den bekannten Aggregationskernen: GLMVGGVVIA 0,91 (C-Terminus), KLVFFAEDVG 0,90 (KLVFF, Reste 16–20); am schwächsten der N-Terminus DAEFRHDSGY 0,07.

```
cd ~/iver_sim/ol_amyloid
PY=~/iver_sim/mamba/envs/iver/bin/python
$PY amylo_gpu.py --import-tsv kontrolle.tsv --rolle kontrolle      # Kandidaten anlegen (acc, kurz, name)
$PY amylo_gpu.py --kandidaten amyloid --bemerkung "43 amyloid candidates"
$PY amylo_gpu.py --acc YP_009724390.1 -w 10
```

### 8.4 Tabellen in `wagodb` (Präfix `amyl_`)

Schema `~/iver_sim/ol_amyloid/amyl_schema.sql`. Jede Angabe steht genau einmal: Kandidat → Sequenzversion → Ergebnis je Lauf → Fenster. Fenstertexte, Fensterzahl und NCBI-Titel/Taxon werden nicht gespeichert, sondern in den Views abgeleitet. Die Kandidatenliste lebt in `amyl_kandidat`, nicht mehr in einer TSV-Datei.

| Tabelle                                                               | Inhalt                                                                                                                                               |
|-----------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>amyl_kandidat</code>                                            | je Protein einmal: Kürzel, Name, Accession ohne Version, Rolle (amyloid / kontrolle / einzel), reife Kette von–bis (NULL = ganze Sequenz), Bemerkung |
| <code>amyl_sequenz</code>                                             | je Sequenzversion einmal: Kandidat, versionierte Accession (wie <code>blast_acc</code> ), Quelle, Länge, Sequenz, SHA1                               |
| <code>amyl_lauf</code>                                                | je Aufruf: Start, Laufzeit, Host, GPU, Software-Stände, Fenstergröße, Zahl der Sequenzen, Bemerkung                                                  |
| <code>amyl_ergebnis</code>                                            | je Lauf und Sequenz: bewerteter Bereich, Mittel, Maximum, Position des Maximums, Laufzeit                                                            |
| <code>amyl_fenster</code>                                             | je Fenster: Position (1-basiert, auf die ganze Sequenz bezogen), Wahrscheinlichkeit                                                                  |
| <code>amyl_v_ergebnis</code> ,<br><code>amyl_v_fenster</code> (Views) | Ergebnisse mit Kandidat, stärkstem Fenster (SUBSTRING), Fensterzahl sowie Titel und Taxon aus <code>blast_acc/blast_seq/blast_taxon</code>           |



ER-Diagramm AmyloDeep (grau: blast\_acc, über die versionierte Accession), erzeugt aus dem Live-Schema (information\_schema). Durchgezogen: deklarierte Fremdschlüssel, gestrichelt: logische Verknüpfungen; Krähenfuß = viele. PK/UK/IX/FK wie in der Datenbank.

Umstellung am 23.09.2026 (amy1\_migration.py, Sicherung amy1\_alt\_20260923.sql): 43 Kandidaten, 43 Ergebnisse, 16.739 Fenster übernommen, abgeleitete Fenstertexte, stärkste Fenster und Fensterzahlen ohne eine Abweichung zum alten Bestand. Schreibweg pymysql über iv\_db.cfg(), jede Sequenz für sich festgeschrieben.

## 8.5 Ergebnis: 43 Amyloid-Kandidaten

Lauf amy1\_lauf.lauf\_id = 1 (23.09.2026 10:42. Tesla P4. Fenster 10): 43 Proteine aus amy1\_kandidat. 16.739 Fenster. 30 min.

- Das Maximum je Protein trennt nicht.** Alle 43 liegen zwischen 0,88 und 0,97. Ohne Negativkontrollen (nicht amyloidogene Proteine gleicher Länge) sagt „max > 0,9“ nichts; swissprot\_title.tsv im selben Ordner ist der naheliegende Kontrollsatz.
- 19 von 43 Maxima liegen in den ersten 30 Resten**, also im Signalpeptid (z.B. AApoAI Pos. 3, AB2M 5, ATTR 8, AIAPP 9). Hydrophobe 10-mere werden hoch bewertet, wie bei allen Aggregations-Vorhersagern. Die Kandidaten sind UniProt-Vorläufer; für Aussagen über Fibrillen gehört die reife Kette ausgewertet.
- Treffer auf bekannten Kernen:** A $\beta$  (Pos. 705 LMVGGVVIAT, C-Terminus von A $\beta$ 42),  $\alpha$ -Synuclein (70 VVTGVTAVAQ, NAC-Kern), Tau (619 GGGSVQIVYK mit PHF6 VQIVYK), FUS (140, Q/S/Y-reiche Low-Complexity-Domäne).
- Daneben:** Sup35 (582, nicht in der N-terminalen Prion-Domäne), PrP (240, GPI-Signal statt Region 106–126), Huntingtin (847, nicht der PolyQ-Abschnitt).

Nächster Schritt: Kontrollsatz und reife Ketten (Signalpeptide aus UniProt abschneiden), dann Verteilungen statt Maxima vergleichen.

| Kürzel | Accession | Länge | Mittel | Max  | Pos. | stärkstes Fenster |
|--------|-----------|-------|--------|------|------|-------------------|
| AKer   | Q15582.1  | 683   | 0,43   | 0,97 | 623  | GVVHVITNVL        |
| HTT    | P42858.2  | 3142  | 0,45   | 0,97 | 847  | LQLIIDVLTL        |
| SUP35  | P05453.1  | 685   | 0,38   | 0,97 | 582  | FVAQIAIVEL        |
| NSER   | P07093.1  | 398   | 0,46   | 0,97 | 107  | IVTVANAVFV        |
| PMEL   | P40967.2  | 661   | 0,41   | 0,97 | 481  | GSFSVTLDIV        |
| ASPC   | P11686.3  | 197   | 0,45   | 0,97 | 39   | VVVVVVLIVV        |
| Abeta  | P05067.3  | 770   | 0,33   | 0,97 | 705  | LMVGGVVIAT        |
| ACys   | P01034.1  | 146   | 0,39   | 0,97 | 11   | LLAILAVALA        |
| AH     | P01857.2  | 399   | 0,39   | 0,97 | 362  | VCYSATVTFF        |
| ATX3   | P54252.5  | 361   | 0,36   | 0,97 | 146  | TYLALFLAQL        |
| AApoAI | P02647.1  | 267   | 0,26   | 0,97 | 3    | AAVLT LAVLF       |
| TDP43  | Q13148.1  | 414   | 0,40   | 0,96 | 26   | VLLSTVTAQF        |

| Kürzel   | Accession | Länge | Mittel | Max  | Pos. | stärkstes Fenster |
|----------|-----------|-------|--------|------|------|-------------------|
| Alns     | P01308.1  | 110   | 0,45   | 0,96 | 94   | QCCTSICSLY        |
| AApoCIII | P02656.1  | 99    | 0,36   | 0,96 | 5    | VLLVVALLAL        |
| AGel     | P06396.1  | 782   | 0,34   | 0,96 | 184  | VVVQRLFQVK        |
| ALys     | P61626.1  | 148   | 0,42   | 0,96 | 8    | GLVLLSVTVQ        |
| AApoAIV  | P06727.4  | 396   | 0,28   | 0,96 | 5    | AVVLTALVA         |
| AIAPP    | P10997.1  | 89    | 0,51   | 0,95 | 9    | FLIVLSVALN        |
| AApoAII  | P02652.1  | 100   | 0,42   | 0,95 | 84   | VNFLSYFVEL        |
| AMed     | Q08431.3  | 387   | 0,43   | 0,95 | 313  | VQFVASYKVA        |
| AB2M     | P61769.1  | 119   | 0,41   | 0,95 | 5    | VALAVLALLS        |
| APro     | P01236.1  | 227   | 0,42   | 0,95 | 108  | FLSLIVSILR        |
| ABri     | Q9Y287.1  | 266   | 0,43   | 0,95 | 62   | AFMLAGVILG        |
| ALac     | P02788.6  | 710   | 0,36   | 0,95 | 5    | FLVLLFLGAL        |
| APrP     | P04156.1  | 253   | 0,35   | 0,95 | 240  | VILLISFLIF        |
| AApoCII  | P02655.1  | 101   | 0,43   | 0,95 | 9    | LFLVLLVLGF        |
| AFib     | P02671.2  | 866   | 0,28   | 0,95 | 6    | IVCLVLSVVG        |
| ACal     | P01258.3  | 141   | 0,35   | 0,95 | 10   | LALSILVLLQ        |
| AANF     | P01160.2  | 151   | 0,26   | 0,95 | 10   | SFLLLLAFQL        |
| CsgA     | P28307.3  | 151   | 0,43   | 0,94 | 5    | KVAAIAAIVF        |
| ATTR     | P02766.1  | 147   | 0,42   | 0,94 | 8    | LLCLAGLVFV        |
| ASem1    | P04279.2  | 462   | 0,28   | 0,94 | 432  | GGLDIVIEEQ        |
| SOD1     | P00441.2  | 154   | 0,35   | 0,94 | 145  | LACGVIGIAQ        |
| AL       | P01834.2  | 107   | 0,36   | 0,94 | 24   | SVVCLLNNFY        |
| AA       | P0DJ18.2  | 122   | 0,31   | 0,94 | 4    | LTGLVFCSLV        |
| ALECT2   | O14960.2  | 151   | 0,38   | 0,93 | 97   | GFCVKMFYIK        |
| AaSyn    | P37840.1  | 140   | 0,36   | 0,93 | 70   | VVTGVTAVAQ        |
| SEVI     | P15309.3  | 386   | 0,38   | 0,92 | 258  | LQGGVLVNEI        |
| ATau     | P10636.5  | 758   | 0,16   | 0,92 | 619  | GGGSVQIVYK        |
| HETS     | Q03689.3  | 289   | 0,37   | 0,92 | 5    | FGIVAGALNV        |
| ACor     | Q15517.4  | 529   | 0,31   | 0,90 | 16   | GMMALLLAGL        |
| AGal7    | P47929.2  | 136   | 0,35   | 0,89 | 32   | RFHVNLLCGE        |
| FUS      | P35637.1  | 526   | 0,31   | 0,88 | 140  | QQSYGQQQSY        |

## 8.6 API und Worker (amylo-api-worker)

AmyloDeep hängt nicht mehr an einer SSH-Sitzung: dieselbe JSON-API wie für DIAMOND nimmt Aufträge entgegen, mit denselben Schlüsseln, derselben Ratenbegrenzung und demselben Warteschlangen-Muster. Der Grund für einen eigenen Worker ist das Modell: es einmal zu laden kostet 6,5 s, und ein Aufruf von `amylo_gpu.py` zahlt das jedes Mal. Der Worker (`systemd amylo-api-worker`, `Env iwer`) hält ESM-2 150M/650M, UniRep, SVM und XGBoost dauerhaft auf der Tesla P4 (4,6 GB) und arbeitet die Aufträge nacheinander ab.

| Aufruf                 | Zugang           | Liefert                                                                                                                                                                          |
|------------------------|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| POST ?r=amylo          | X-API-Key        | legt einen Auftrag an: <code>acc</code> (aus nr, optional von/bis) <b>oder</b> <code>seq, window 4–40</code> (Standard 10); Antwort 202 mit <code>job_id</code> und Ergebnis-URL |
| GET ?r=amylojob&id=... | wer die id kennt | Status, Parameter, Laufzeit; wenn fertig Mittel, Maximum, stärkstes Fenster und alle Fensterwerte                                                                                |

Grenzen wie bei der Suche: höchstens 3 offene Aufträge und ein Tageskontingent je Schlüssel, 60 Anfragen je Minute, bis 5.000 Reste je Auftrag. Der Benutzer `blast_api` darf `amyl_job` schreiben und die Ergebnistabellen nur lesen. Jeder Auftrag erzeugt einen eigenen `amyl_lauf`, die Werte landen in denselben Tabellen wie die Läufe von Hand (8.4) – ein API-Ergebnis ist damit später genauso auswertbar.

## 8.7 Durchsatz auf der P4

301 Aufträge des Workers stehen mit Laufzeit in `amyl_lauf`, zusammen 117.150 Fenster in 212 min. Die Laufzeit hängt linear an der Fensterzahl ( $R^2 = 0,9985$ ), eine Ausgleichsgerade trennt daher sauber den festen Anteil je Auftrag vom Rechenanteil je Fenster.

$$t = 0,69 \text{ s} + 0,1067 \text{ s} * \text{Fenster}$$

| Größe                                | Wert                   |
|--------------------------------------|------------------------|
| Fenster/s (Steigung)                 | 9,37                   |
| je Fenster                           | 107 ms                 |
| fest je Auftrag                      | 0,69 s                 |
| Fenster/s je Auftrag                 | 7,62–9,50, Median 9,25 |
| Protein mit 1.000 Resten             | rund 107 s             |
| Stapel: 43 Sequenzen in einem Aufruf | 9,18 Fenster/s         |

Ein Fenster je Restposition: Fenster/s und Reste/s sind damit praktisch dasselbe. Der feste Anteil je Auftrag ist klein, weil die Modelle im Worker geladen bleiben – ein Aufruf von `amylo_gpu.py` zahlt stattdessen jedes Mal die Ladezeit aus 8.6. Ein Stapel mehrerer Sequenzen in einem Aufruf bringt nichts mehr: die P4 ist schon mit den Fenstern einer einzigen Sequenz ausgelastet.

Die Ausgleichsgerade misst einzelne Aufträge. Ob die Kette aus API, Warteschlange und Worker auch unter Dauerlast trägt, zeigt erst ein ganzer Durchlauf: am 23.09.2026 liefen 301 Aufträge von 13:18–16:58 am Stück durch, 301 fertig, 0 gescheitert.

| Größe                     | Wert                            |
|---------------------------|---------------------------------|
| Wanduhr                   | 3,66 h                          |
| Rechenzeit auf der P4     | 3,53 h                          |
| Auslastung des Workers    | 96,4 %                          |
| Durchsatz                 | 82,2 Aufträge/h                 |
| Wartezeit in der Schlange | im Mittel 76 s, längstens 150 s |

Bei 96,4 % Auslastung lief die Warteschlange über 3,66 h nie leer: der Engpass ist die P4, nicht die API und nicht die Einreichung. Kein Auftrag ging verloren, die Wartezeit blieb unter 150 s – der Worker arbeitet die Schlange so schnell ab, wie sie gefüllt wird.

Gegen die CPU-Fassung (Abschnitt 8.3, A<sub>β</sub>42: 4,4 s gegen 43,4 s) ist das etwa das Zehnfache. Alle Zahlen gelten für Fenster der Größe 10; die P4 ist dabei zu 100 % ausgelastet und zieht 55–65 W bei 75–77 °C (nvidia-smi, 23.09.2026).

## 8.8 Beispiel: eine Literaturaussage prüfen (Spike 194–203)

Der Fall zeigt, was die Teile zusammen leisten. Ausgangspunkt ist eine Angabe aus der Literatur (Nyström & Hammarström, JACS 2022, hier als Vorgabe übernommen und **nicht** nachgeprüft): im SARS-CoV-2-Spike gebe es sieben amyloidogene Abschnitte, und das Fragment **194–203** bilde nach Spaltung durch neutrophile Elastase Fibrillen. Geprüft wird nur, ob AmyloDeep diesen Abschnitt auffällig findet; Spaltstellen sagt das Modell nicht vorher.

Aus 8.5 folgt die Methodik: ein hoher Wert allein sagt nichts, weil alle 43 bekannten Amyloidbildner zwischen 0,88 und 0,97 lagen. Es braucht zwei Bezugsgrößen: **intern** den Rang des Fensters 194 unter allen Fenstern des Spike, **extern** die Verteilung der Fenster eines Kontrollsatzes zufälliger humaner SwissProt-Proteine (100–800 aa, bekannte Amyloidbildner ausgeschlossen, feste Zufallszahl).

`~/iver_sim/ol_amyloid/spike_amyloid_test.py` legt Kandidaten und Kontrollen an und wertet danach aus; gerechnet wird über die API (8.5), der Worker hält das Modell bereit:

```
# Kandidat und 300 SwissProt-Kontrollen anlegen
python3 spike_amyloid_test.py --vorbereiten --n-kontrollen 300 --seed 42

# Auftrag ueber die API (Abschnitt 8.5) - kein SSH, kein Modell-Laden
curl -X POST -H "X-API-Key: $K" -H 'Content-Type: application/json' \
  -d '{"acc": "YP_009724390.1", "window": 10}' \
  'https://yt.heissa.de/blast/api.php?r=amylo'
-> {"job_id": "0f478cae...", "status": "queued", "position": 1, "url": "...r=amylojob&id=..."}

curl 'https://yt.heissa.de/blast/api.php?r=amylojob&id=0f478cae...'
python3 spike_amyloid_test.py --auswerten
```

**Was dabei ineinandergreift** – und warum das ohne den Unterbau der vorigen Abschnitte Tage statt Minuten dauern würde:

| Schritt                                       | Grundlage                                | Aufwand                          |
|-----------------------------------------------|------------------------------------------|----------------------------------|
| Spike-Sequenz und 300 Kontrollsequenzen holen | lokale nr per Accession (Abschnitt 4, 9) | ~0,3 s je Sequenz, kein Download |

| Schritt                    | Grundlage                                                                        | Aufwand                                                   |
|----------------------------|----------------------------------------------------------------------------------|-----------------------------------------------------------|
| Kontrollen auswählen       | swissprot_titel.tsv lokal, Filter nach Organismus, Länge und Titel               | 15.603 Kandidaten, Auswahl per Zufallszahl reproduzierbar |
| Amyloid-Neigung je Fenster | ESM-2 650M + Ensemble auf der Tesla P4 (8.1–8.3), eingereicht über die API (8.5) | 1.264 Fenster in 136 s; GPU 100 %, 78 °C                  |
| Ergebnisse ablegen         | amy1_* in wagodb, je Angabe einmal (8.4)                                         | Auswertung als SQL statt als Dateiwust                    |
| Nachvollziehbarkeit        | amy1_lauf hält Zeit, GPU, Software-Stände, Fenstergröße fest                     | jeder Wert im PDF ist auf einen Lauf zurückführbar        |

**Ergebnis** (Lauf 2, 1273 aa, Fenster 10): das Fenster ab Position 194 (FKNIDGYFKI) erreicht 0,630 und liegt damit auf Rang 460 von 1.264 Fenstern des Spike-Proteins, also über 64 % der übrigen Abschnitte.

| Rang | Position | Fenster    | Wert  |
|------|----------|------------|-------|
| 1    | 1218     | LGFIAGLIAI | 0,971 |
| 2    | 606      | NQVAVLYQDV | 0,964 |
| 3    | 607      | QVAVLYQDVN | 0,958 |
| 4    | 1059     | GVVFLHVTYV | 0,958 |
| 5    | 1222     | AGLIAIVMVT | 0,953 |

**Die Vorhersage stützt die Angabe nicht.** Das Fragment liegt im Mittelfeld des eigenen Proteins, nicht an der Spitze. Die höchsten Werte stehen auf hydrophoben Abschnitten der Transmembran- und Fusionsregion (1218, 1222, 1059) – dasselbe Muster wie bei den 43 Kandidaten, wo 19 Maxima im Signalpeptid lagen. Mögliche Gründe, keiner davon hier geprüft: AmyloDeep bewertet ein Fenster für sich, nicht das Verhalten eines durch Elastase freigesetzten Peptids; die zitierte Arbeit ist experimentell, nicht vorhersagend; und andere Verfahren (WALTZ, AGGRESCAN, ZipperDB) können anders urteilen. Belegt ist nur: **dieses** Modell findet **diesen** Abschnitt unauffällig.

**Gegen die Kontrollen:** 300 humane SwissProt-Proteine ergeben 115.886 Fenster; 23,28 % davon erreichen 0,630 oder mehr. Je kleiner dieser Anteil, desto auffälliger wäre das Fragment; bei diesem Anteil hebt es sich nicht vom Hintergrund ab. Zum Maßstab: das stärkste Fenster eines Kontrollproteins liegt im Mittel bei 0,930, im Höchstfall bei 0,976 – ein hoher Einzelwert ist hier also der Normalfall, kein Befund.

## 9. Doppelte Datenhaltung auflösen

Dieselben Sequenzen lagen zweimal auf dem dell: als BLAST-nr und als DIAMOND-Datenbank. **Stand 24.09.2026:** Die BLAST-nr ist nicht mehr vorhanden, es gilt nur noch die DIAMOND-Datenbank; die Tabelle unten und die Zahlen zur BLAST-nr sind der Ausgangszustand.

| Datenbestand                      | Größe                                       | Ort                       | Stand                               |
|-----------------------------------|---------------------------------------------|---------------------------|-------------------------------------|
| ~/blastdb/nr (BLAST, 176 Volumes) | 857 GB                                      | System-NVMe (78 % belegt) | eingefroren 16.09.2026              |
| nr_full.dmnd (DIAMOND)            | Neubau läuft (ohne Titel, erwartet ~460 GB) | /mnt/archive (sda5)       | per Cron fortgeschrieben (5.2, 5.3) |
| Metadaten blast_*                 | 2 × ~52 GB + Indizes (hochgerechnet, 6.1)   | MariaDB (NVMe)            | per Cron fortgeschrieben (6.4)      |

Suche, Append und Tagesdelta brauchen die BLAST-nr nicht mehr (die Hash-Arrays für den Duplikatabgleich sind gebaut). Übrig ist ein einziger Zweck: **Residuen zu einer Accession holen** (API `acc`, `amylo_gpu.py`). Die Metadaten in MariaDB helfen dabei nicht, `blast_seq` enthält Länge und Titel, aber keine Sequenz. Dazu kommt ein Fehler im Ist-Zustand: die Cron-Skripte hängen neue Sequenzen nur an .dmnd und MariaDB an, nicht an die BLAST-nr. Eine per Tagesdelta hinzugekommene Accession steht in `blast_acc`, `blastdbcmd` findet sie aber nicht.

### 9.1 Titel liegen dreifach vor

Die BLAST-nr besteht nur zu gut der Hälfte aus Sequenzen: .psq 436 GB (1 Byte je Rest), .phr 270 GB Kopfzeilen, ~155 GB Accession- und Taxon-Indizes (`nr.pdb` als LMDB allein 99 GB), ~45 GB OID-Indizes. Grund: nr fasst identische Sequenzen zusammen, behält aber jede Defline – 1,15 Mrd. Sequenzen, 1,94 Mrd. Deflines; ein Titel ist im Mittel ~139 Byte, eine Sequenz 377 Reste.

Die .dmnd enthält dieselben Titel noch einmal. `diamond_pipeline.sh` ruft `blastdbcmd -entry all ohne -outfmt`

auf; das liefert FASTA mit der zusammengefassten Kopfzeile aller identischen Einträge, getrennt durch „>“ (Spike YP\_009724390.1: 29 Defines, 2.634 Byte Titel zu 1.273 Resten). FastaFile übernimmt die ganze Zeile als ID (src/data/fasta/fasta\_file.cpp:231), push\_seq schreibt sie vollständig hinter die Residuen (0xFF, Residuen, 0xFF, ID, Nullbyte; src/legacy/dmnd/dmnd.cpp). Gebraucht werden davon nur die Accessions: accession\_from\_title zerlegt die Zeile an \1 bzw. „>“ (FASTA\_HEADER\_SEP, src/util/sequence/sequence.cpp:38) und füllt damit die Taxon-Listen. Grob 120 GB der .dmnd sind Titeltext (genaue Zahl nach Abschluss des Builds aus dem Trailer). Die dritte Kopie ist blast\_seq.title in MariaDB (nur der erste Titel je Sequenz).

**Umgesetzt im Neubau vom 23.09.2026 (nr\_build.py, Abschnitt 4):** Kopfzeile nur noch aus den Accessions (>acc1 >acc2 ...). Taxon-Listen bleiben vollständig, die Suchausgabe sseqid ist ohnehin nur das erste Wort, Titel kommen für die API aus MariaDB. Die .dmnd wird dadurch rund 100 GB kleiner; die Titel liegen danach nur noch zweimal vor (.phr und blast\_seq.title), nach dem Löschen der BLAST-nr einmal.

## 9.2 Warum nicht diamond getseq

diamond getseq (SequenceFile::get\_seq(), src/data/sequence\_file.cpp:395) hat keinen Index: die Schleife liest alle sequence\_count() Sätze der Reihe nach und gibt die ausgewählten aus. --seq erwartet Satznummern, nicht Accessions; Titel-Listen werden ebenfalls nur während dieses Durchlaufs verglichen. Für eine einzelne Accession hieße das 495 GB lesen – Stunden statt Millisekunden.

## 9.3 Direktzugriff: dmnd\_getseq.py

Die .dmnd hat alles, was für einen Direktzugriff nötig ist: im Trailer liegt ab pos\_array\_offset (Header) die Offset-Tabelle, 16 Byte je Satz (SeqInfo: pos u64, seq\_len u32, src/data/sequence\_file.h:130). Geplantes Skript, reines Python, ohne DIAMOND-Aufruf:

1. Accession → OID über blast\_acc (Index idx\_acc). Deckt Erstimport, Release-Append und Tagesdelta ab.
2. OID → Satznummer der .dmnd: OID minus Zahl der Leersequenzen mit kleinerer OID. Die Leersequenzen schreibt nr\_build.py beim Bau in blast\_dmnd\_luecke; angehängte Sequenzen erzeugen keine neuen Lücken, --append lehnt Länge 0 ab (5.1).
3. Satznummer → Offset: ein seek auf pos\_array\_offset + 16·n, 16 Byte lesen.
4. Offset → Residuen: ein seek, seq\_len Bytes lesen, DIAMOND-Buchstabencode in Aminosäuren zurückübersetzen.
5. Kontrolle bei jedem Zugriff: hinter den Residuen steht die Kopfzeile des Satzes (9.1); die gesuchte Accession muss darin vorkommen, und seq\_len muss blast\_seq.len entsprechen. Sonst stimmt die Lücken-Tabelle nicht – Fehler statt falscher Sequenz.

Kosten: zwei Zufallszugriffe auf sda5, Millisekunden. Die Sequenzen sind damit immer auf dem Stand der fortgeschriebenen .dmnd, auch für Accessions aus dem Tagesdelta. Während eines Appends ändert sich die Offset-Tabelle; das Skript nimmt deshalb dieselbe geteilte Sperre /home/gh/.nr\_dmnd.lock wie der API-Worker.

## 9.4 Umstellung und Freigabe

1. dmnd\_getseq.py gebaut (Offset-Tabelle, blast\_dmnd\_luecke, idx\_acc). Umgesetzt.
2. Abgleich: gegen blastdbcmd nicht mehr möglich, die BLAST-nr existiert nicht mehr. Stattdessen gegen die 344 in amy1\_sequenz gespeicherten Originalsequenzen (aus der früheren BLAST-nr, 16.09.): mit NCBI-Fallback 344/344 identisch, ohne 220/344 (die übrigen 124 gleich lang, nur durch X-Maskierung anders).
3. api.php (acc) und amylo\_gpu.py (--acc, --kandidaten) rufen nr\_seq.py auf statt blastdbcmd. Umgesetzt am 24.09.2026; api.php läuft als Benutzer www-data, nr\_seq.py setzt dafür HOME selbst.
4. ~/blastdb ist leer, die BLAST-nr nicht mehr vorhanden.
5. nr\_full.dmnd liegt auf der System-NVMe: /home/gh/diamond/nr\_full.dmnd ist die maßgebliche Datei. Worker, diamond\_append.py, nr\_daily\_delta.py, dmnd\_getseq.py und blast\_release.dmnd\_datei zeigen darauf; die Kopie auf /mnt/archive (sda5) heißt NICHT\_VERWENDEN\_nr\_full.dmnd.alt\_nutze\_home\_gh\_diamond, damit sie nicht irrtümlich benutzt wird. Der Hash-Cache nr\_seq\_hashes.npy liegt weiter auf /mnt/archive.

## 9.5 X-Maskierung und NCBI-Fallback (nr\_seq.py)

makedb maskiert Bereiche niedriger Komplexität hart zu X, das Original steht nicht in der .dmnd (gemessen: 1,97 % der Residuen, 14,5 % der Sequenzen). Die vorgesehene Rückholtabelle blast\_mask (nr\_mask\_build.py) gibt es nicht: sie braucht einen Lauf durch die BLAST-nr, die nicht mehr existiert. nr\_seq.py löst das pro Anfrage: Accession → OID (blast\_acc), Satz aus der .dmnd. Enthält die Sequenz ein X, oder kennt blast\_acc die Accession nicht, kommt das Original per NCBI-efetch (eine Accession, wenige kB, Frist 40 s, höchstens 3 Anfragen je Sekunde). Übernommen wird nur eine Sequenz gleicher Länge, die außerhalb der X-Stellen identisch ist; sonst bleibt die maskierte Sequenz und stderr warnt. Aufruf: nr\_seq.py P02766.1 --range 20-70 (1-basiert, beide Enden inklusiv); als Modul aus\_nr(acc).

## 9.6 Speicherbudget der Suche (64 GB RAM)

Der dell hat 64 GB RAM, dauerhaft belegt sind ~29 GB (nach Abschalten der nicht genutzten Dienste; MariaDB mit 8,6 GB Buffer Pool ist einer der größeren). Eine Suche gegen die volle nr mit der Vorgabe --block-size 2 hält 15 bis 17 GB RSS; das Budget für alles zusammen ist 48 GB. Geplant ist eine Suche in zwei Stufen: (1) ein MariaDB-SELECT wählt Kandidaten so, dass der Speicherbedarf unter 48 GB bleibt (vorgesehen: Taxonomie-Ringe über blast\_acc.taxid, von der Art der Query nach außen), (2) DIAMOND sucht in der Teilmenge; liefert sie weniger als max\_target\_seqs Treffer, folgt der nächste Ring, bis alles gefunden ist. Achtung: Die Ergebnisse sind nur so vollständig wie der Ring, in dem sie liegen; der letzte Ring ist die volle nr mit --block-size als Speicherdeckel. Zuerst wird --block-size allein gemessen (Skript diamond\_blocksize\_test.sh, Query TTR 20-70).

**Umgesetzt (30.09.2026):** statt Taxonomie-Ringen die Vorauswahl nach Taxon, Länge und Anlagedatum (Abschnitt „Vorauswahl über MariaDB“) und die RAM-Planung je Suche (Abschnitt „RAM-Planung jeder Suche“): Grenze aus dem tatsächlich freien Speicher, --block-size passend gewählt.

## 9.7 Test der API (extern)

Ein Test zählt nur, wenn er von außen läuft: ssh gh@heissa.de curl 'https://yt.heissa.de/blast/api.php?r=...'. Vom dell oder Arbeitsplatz aus löst yt.heissa.de nicht auf; ein Aufruf gegen localhost mit --resolve prüft nur den Server, nicht den Weg dorthin.

## 10. Mögliche nächste Stufe

Falls DIAMOND bei sehr entfernten Homologien nicht ausreicht: Zwei-Stufen-Suche über Protein-Embeddings, die dasselbe Muster wiederverwendet, das bereits für die Wissensbasis (vec\_-Tabellen in wagodb, MariaDB VECTOR mit HNSW-Index, Embedding-Server auf der P4) produktiv läuft: Sequenzen als Vektoren ablegen, per VEC\_DISTANCE\_COSINE vorfiltern, nur die Kandidaten anschließend exakt mit DIAMOND/BLAST nachprüfen. Die ESM-2-650M-Umgebung aus Abschnitt 8 liefert solche Embeddings bereits.